
Caso de Uso Práctico

Predicción de Diagnóstico de Cáncer:
Viabilidad del Proyecto mediante Machine Learning
y Redes Neuronales

Asignatura: Inteligencia Artificial

Titulación: Ingeniería Matemática

Curso: 2025–2026

1. Presentación del caso

Un hospital universitario recoge datos multimodales de sus pacientes y quiere saber si esos datos son suficientes para anticipar, con modelos de Inteligencia Artificial, si un paciente va a recibir o ya tiene un diagnóstico de cáncer. El objetivo es doble: **evaluar la viabilidad del proyecto** comparando distintos algoritmos de Machine Learning (ML) frente a una Red Neuronal Multicapa (MLP), y **recomendar la estrategia de modelado** que mejor encaje en un sistema de cribado clínico real.

Como equipo de científicos de datos, debéis construir el pipeline completo de ML, ejecutar la comparativa y presentar vuestras conclusiones en un estudio de cinco diapositivas.

2. Datos disponibles

Se proporcionan **seis ficheros CSV** que simulan las colecciones de una base de datos documental MongoDB. Todos comparten la clave `paciente_id` y contienen **50 001 registros** de pacientes sintéticos generados con criterios epidemiológicos reales.

Fichero de metadata adjunto

El fichero `metadata_dataset_cancer.md` (adjunto en el campus virtual junto a los CSV) contiene la descripción completa de cada campo: tipo de dato, rango de valores, media/prevalencia y advertencias de uso. **Su lectura es obligatoria antes de comenzar el análisis.**

3. Qué se pide

3.1. Análisis de viabilidad: comparativa de modelos

Construid en Python un pipeline completo que incluya:

1. **Carga y unión** de los ficheros CSV por `paciente_id`.
2. **Selección de features** con justificación (consultad `metadata_dataset_cancer.md`).
3. **Preprocesamiento**: codificación de categóricas, normalización (`StandardScaler`), división estratificada 80 %/20 %.
4. Entrenamiento y evaluación de **al menos 3 modelos de ML complejos + 1 Red Neuronal Multicapa (MLP)**.

La **Red Neuronal MLP** debe tener al menos tres capas ocultas, usar Dropout y Early Stopping, y gestionar el desbalance de clases mediante `class_weight`.

3.2. Métricas a calcular para cada modelo

Sobre el conjunto de test (20 %):

- Precisión, Recall y F1-Score para la clase `cancer = 1`.
- AUC-ROC.
- Accuracy global (solo como referencia, no como criterio principal).


4. Tarea Principal: Diseño y Validación de la Red Neuronal

Entre todas las tareas del proyecto, el diseño, entrenamiento y validación de la **Red Neuronal Multicapa (MLP)** constituye el núcleo técnico del trabajo. No se trata únicamente de entrenar un modelo más: la red neuronal actúa como **referencia avanzada** frente a la que se miden todos los algoritmos clásicos, y su correcta construcción determina la fiabilidad del estudio comparativo.

Esta tarea se divide en dos fases inseparables: el **diseño de la arquitectura** y la **validación del entrenamiento** mediante curvas de pérdida y aprendizaje.

4.1. Fase 1: Diseño de la arquitectura

La arquitectura de la red debe justificarse, no simplemente copiarse. Cada decisión de diseño —número de capas, neuronas por capa, función de activación, técnica de regularización— responde a una característica del problema médico que estáis resolviendo:



4.1.1. Estrategias de regularización

La regularización es especialmente crítica en este problema porque el dataset, aunque sintético, replica la variabilidad biológica real mediante ruido gaussiano en la función generadora. Sin regularización, una red con 46.913 parámetros puede memorizar patrones espurios del conjunto de entrenamiento:

- **BatchNormalization:** normaliza las activaciones de cada capa antes de pasarlas a la siguiente, acelerando la convergencia y reduciendo la sensibilidad a la tasa de aprendizaje inicial. Permite usar tasas de aprendizaje más altas sin inestabilidad.
- **Dropout:** en cada paso de entrenamiento, desactiva aleatoriamente el 25 % de las neuronas en las dos primeras capas ocultas y el 20 % en la tercera. Esto obliga a la red a aprender representaciones redundantes y robustas, equivalente a entrenar un ensemble implícito de subredes.

- **Early Stopping** (paciencia = 12 épocas): detiene el entrenamiento cuando la pérdida de validación deja de mejorar durante 12 épocas consecutivas, evitando el sobreajuste tardío y reduciendo el tiempo de cómputo.
- **ReduceLROnPlateau** (factor = 0.5, paciencia = 6 épocas): reduce la tasa de aprendizaje a la mitad cuando la pérdida de validación se estanca. Permite que la red “afine” los pesos en las etapas finales del entrenamiento sin saltar sobre el mínimo.

4.1.2. Ajuste del umbral de clasificación

La red neuronal, por defecto, clasifica como positivo (cáncer) a todo paciente con $P(\hat{y} = 1) > 0,5$. Sin embargo, dado el desequilibrio de clases y el coste asimétrico de los errores en oncología, este umbral no es óptimo. El procedimiento correcto es:

1. Calcular las probabilidades predichas sobre el **conjunto de validación** (no el de test).
2. Barrer umbrales en el intervalo $[0,1, 0,9]$ con paso 0.01.
3. Seleccionar el umbral que maximiza el **F1-score** sobre la clase positiva en validación.
4. Aplicar ese umbral **una sola vez** sobre el conjunto de test.

Advertencia

Error frecuente: optimizar el umbral directamente sobre el conjunto de test es una forma de fuga de datos (*data leakage*). El umbral debe determinarse siempre sobre datos que el modelo no ha visto durante la evaluación final. En este estudio, el umbral óptimo resulta ser **0.57**: subir el umbral por encima de 0.5 reduce las falsas alarmas (mejora la precisión) a costa de un ligero descenso en recall.

5. Entregable: estudio en 5 diapositivas

Entregable

El resultado del caso es un **estudio de viabilidad** presentado en exactamente **5 diapositivas** (formato PDF o PowerPoint), con el siguiente contenido obligatorio en cada una:

Objetivo y datos del proyecto.

Breve descripción del caso (2–3 líneas), tabla resumen de las colecciones usadas, variable objetivo, prevalencia y razón de desbalance. Decisión sobre qué variables se incluyen y cuáles se excluyen, con justificación.

Resultados de los modelos de ML complejos.

Tabla comparativa (Precisión / Recall / F1 / AUC-ROC) de los modelos seleccionados. Matriz de confusión del mejor modelo ML. Comentario sobre el impacto del desbalance de clases.

Resultados de la Red Neuronal (MLP).

Arquitectura utilizada (capas, neuronas, regularización). Curvas de pérdida y accuracy por época. Métricas sobre test. Comparación directa con el mejor modelo ML.

Comparativa global ML vs. Red Neuronal.

Gráfico de barras comparativo de todas las métricas. Curvas ROC superpuestas. Análisis del espacio Precisión–Recall. Tabla resumen con el ranking de modelos.

Viabilidad del proyecto y decisión.

¿Son los datos suficientemente buenos para anticipar el cáncer? ¿Qué modelo implantaríais en el hospital y por qué? Limitaciones del sistema actual. Qué datos adicionales mejorarían la predicción.

Junto a las 5 diapositivas se entrega el código fuente (.py o .ipynb), ejecutable y comentado.

6. Criterios de evaluación

El caso tiene carácter optativo. Si se realiza se tendrá en cuenta para la nota media de la evaluación continua si la media favorece con los dos casos obligatorios. Si la nota del caso está entre 9.0 y 9.4, además se sube +0.5 en el examen final de ordinaria. Si la nota es de 9.5 a 10.0 además de la nota en evaluación continua se sube +1 punto en el examen final.